

Môn thi: Nhập môn phân tích dữ liệu
Mã môn học: HUS1023 **Số tín chỉ:** 2
Thời gian: **60 phút**, không kể thời gian phát đề.
(Đề thi không sử dụng tài liệu)

Dữ liệu **Insurance** chứa thông tin về 1.338 bệnh nhân hiện đang tham gia chương trình bảo hiểm, với các đặc điểm cho biết thông tin của họ cũng như tổng chi phí y tế được tính vào chương trình trong năm dương lịch tại Hoa Kỳ. Dữ liệu được lấy từ thư mục `D:\ptdl\insurance.csv` với các biến sau:

age: Tuổi của người thụ hưởng bảo hiểm;
sex: Giới tính của người thụ hưởng.;
children: Số lượng con cái của người thụ hưởng;
smoker: Người thụ hưởng có hút thuốc lá hay không;
region: Nơi cư trú của người thụ hưởng tại Hoa Kỳ, bao gồm: đông bắc (northeast), đông nam (southeast), tây nam (southwest), hoặc tây bắc (northwest);
charges: Tổng chi phí y tế của người thụ hưởng bảo hiểm.

age	sex	bmi	children	smoker	region	charges
19	female	27.900	0	yes	southwest	16884.924
18	male	33.770	1	no	southeast	1725.552
28	male	33.000	3	no	southeast	4449.462
33	male	22.705	0	no	northwest	NA
32	male	28.880	0	no	northwest	3866.855
31	female	25.740	0	no	southeast	3756.622
46	female	33.440	1	no	southeast	8240.590
37	female	27.740	3	no	northwest	7281.506
37	male	29.830	2	no	northeast	6406.411
60	female	25.840	0	no	northwest	28923.137
25	male	26.220	0	no	northeast	2721.321
62	female	26.290	0	yes	southeast	27808.725
23	male	34.400	0	no	southwest	1826.843
56	female	39.820	0	no	southeast	11090.718
27	male	42.130	0	yes	southeast	39611.758

Thực hiện các thao tác sau với phần mềm R.

1. Nhập dữ liệu trên vào R và đặt tên nó là data. Hãy cho biết trong các biến trên biến nào là biến định lượng, biến nào là biến định tính.
2. Hãy cho biết biến “tổng chi phí y tế – charge” có bao nhiêu giá trị trống, hãy thay thế chúng bằng giá trị trung vị của biến đó.
3. So sánh độ tuổi trung bình của bệnh nhân sống tại đông bắc (northeast) và độ tuổi trung bình của bệnh nhân sống tại đông nam (southeast).
4. Hãy tính chi phí y tế trung bình theo từng khu vực và đưa ra tên khu vực có chi phí y tế trung bình cao nhất.
5. Nhằm mô phỏng chính xác biến Charges, một mô hình ngẫu nhiên được xây dựng nhằm sinh ra 4 biến Charges giả (Ký hiệu lần lượt là X_1, X_2, X_3, X_4) là một số liên tục có phân phối chuẩn với trung bình và độ lệch tiêu chuẩn thỏa mãn với $n = 1, \dots, 4$

$$\mu_n = \mu_{n-1}$$

và

$$\sigma_n = \frac{1}{2}(\sigma_{n-1}^2 + 2h + (\sigma_{n-1}^2 + 4h)^{1/2})$$

ở đó, h là bước nhảy nhỏ tùy ý μ_0, σ_0 lần lượt là trung bình và độ lệch tiêu chuẩn của biến Charges. Hãy thêm 4 biến kể trên vào dữ liệu, sau đó tính sai số tiêu chuẩn của hiệu giữa Charges và lần lượt 4 biến trên.

6. Hãy cho biết trong 4 biến vừa tạo ra ở ý trên, biến nào có sai tiêu chuẩn của hiệu giữa Charges và nó là nhỏ nhất.
7. Hãy tạo một biến mới để phân loại chỉ số BMI của các bệnh nhân, trong đó
 - BMI < 18.5: Gầy
 - 18.5 < BMI < 24.9: Bình thường
 - 25 < BMI < 29.9: Thừa cân
 - BMI > 30: Béo phì

Hãy lập bảng tần số cho biến mới này.

8. Tìm khoảng tứ phân vị của biến tổng chi phí y tế (charges). Sử dụng phương pháp 3Q (về các mức tứ phân vị) để loại bỏ dữ liệu bất thường của biến tổng chi phí y tế.
9. Hãy vẽ biểu đồ cột thể hiện cấu thành giới tính theo từng khu vực.
10. Hãy vẽ tổ chức đồ (histogram) thể hiện chi phí y tế của các bệnh nhân tại Hoa Kỳ và thêm đường mật độ vào biểu đồ.